# Compressão de Imagens via Decomposição em Valores Singulares

Matheus Henrique Gomes dos Santos[1], Leandro da Fonseca Prudente[2]

[1]Estudante, Instituto de Matemática e Estatística (IME), matheus_henrique2@discente.ufg.br
[2]Orientador, Instituto de Matemática e Estatística (IME), lfprudente@ufg.br

## Resumo

A decomposição em valores singulares (SVD) é um método algébrico que permite escrever uma matriz como $A = U\Sigma V^T$, em que $\Sigma$ contém os valores singulares em ordem decrescente. A compressão via SVD trunca esses valores, descartando os menores e gerando uma aproximação de menor posto da matriz original. Para analisar esse processo, o método é aplicado a imagens digitais, interpretando cada pixel como $a_{ij}$ (tons de cinza) ou $a_{ij}^{(R)}$, $a_{ij}^{(G)}$ e $a_{ij}^{(B)}$ (coloridas). A SVD foi implementada na linguagem Julia, devido ao seu alto desempenho para problemas desse tipo, possibilitando reconstruir aproximações da imagem, determinar o ponto de truncagem limite $k_{\text{max}}$, em que a taxa de compressão (*Compression Ratio*) atinge $CR \approx 1$, e avaliar os valores de compressão real ($k < k_{\text{max}}$) com maior exatidão, enquanto os gráficos utilizados na análise dos resultados foram construídos em Python. A qualidade do resultado é mensurada por meio do PSNR, do MSE e da norma de Frobenius do erro.

**Palavras-chave:** Compressão, Imagens, Matrizes, Otimização, SVD.

## 1 Apresentação

Com a crescente demanda por armazenamento e transmissão de imagens digitais, é necessário utilizar técnicas de compressão que reduzam o volume de dados sem comprometer sua qualidade. A Decomposição em Valores Singulares (SVD) é uma ferramenta da Álgebra Linear que permite obter aproximações de posto $k$ de matrizes e, nesse contexto, reúne fundamentos teóricos e práticas computacionais aplicados à compressão de imagens. O objetivo deste trabalho consiste em investigar e analisar a aplicação dessa técnica em imagens digitais, tanto em tons de cinza quanto coloridas, avaliando, em ambos os casos, o impacto da redução do posto matricial na qualidade da reconstrução por meio de métricas quantitativas, uma vez que a avaliação exclusivamente visual é empírica e subjetiva.

## 2 Metodologia

Uma imagem em tons de cinza é modelada por uma matriz de números inteiros no intervalo $[0, 255]$, em que cada valor corresponde à tonalidade de um pixel, variando do preto ao branco. Para os experimentos, os valores foram normalizados no intervalo $[0, 1]$. Assim, a imagem é associada à matriz $A \in \mathbb{R}^{n\times m}$, na qual cada elemento $a_{ij}$ representa a intensidade do pixel

da posição $(i, j)$. No caso de imagens coloridas, a imagem é decomposta em três matrizes correspondentes aos canais RGB: vermelho (R), verde (G) e azul (B), de modo que $A(R, G, B)$ representa a imagem por meio dessas três componentes de cor.

O processo é feito nas seguintes etapas:

1. **Decomposição SVD:** A matriz da imagem é decomposta na forma $A = U\Sigma V^T$, em que $U$ e $V$ são matrizes ortogonais e $\Sigma$ é uma matriz diagonal em que os valores singulares estão organizados em ordem decrescente ($\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r \geq 0$). No caso de imagens coloridas, a decomposição é realizada separadamente em cada um dos três canais.

2. **Compressão por truncagem de posto $k$:** A compressão é feita mantendo apenas os $k$ maiores valores singulares e descartando os demais, ou seja, considerar um posto $k$ significa utilizar apenas as $k$ primeiras componentes da matriz $\Sigma$, as quais representam as informações mais relevantes da imagem, como a estrutura global, a iluminação e os contornos principais. O Teorema de Eckart-Young garante que essa aproximação $A_k$ é a melhor possível para o valor de $k$ escolhido, aplicando-se esse mesmo parâmetro a cada um dos três canais nas imagens coloridas.

3. **Cálculo do erro e qualidade:** Para avaliar a qualidade da imagem reconstruída após a compressão em diferentes valores de $k$, são calculadas três métricas de erro:

   - Norma de Frobenius do erro ($\|A - A_k\|_F$);
   - Erro Quadrático Médio (MSE);
   - Razão Sinal-Ruído de Pico (PSNR).

## 3 Teorema da Decomposição em Valores Singulares (SVD)

Considere uma matriz $A \in \mathbb{R}^{n\times m}$. A decomposição em valores singulares estabelece que é possível representar essa matriz a partir de duas matrizes ortogonais e uma matriz diagonal cujas entradas satisfazem $\sigma_{ij} \neq 0$ se $i = j$ e $\sigma_{ij} = 0$ se $i \neq j$, correspondentes aos valores singulares de $A$. Esta representação é formalizada pelo seguinte teorema:

**Teorema.** Seja $A \in \mathbb{R}^{n\times m}$ uma matriz não nula de $\text{posto}(A) = r$. Então $A$ pode ser expressa como o produto

$$A = U\Sigma V^T, \tag{1}$$

onde $U \in \mathbb{R}^{n\times n}$ e $V \in \mathbb{R}^{m\times m}$ são matrizes ortogonais, e $\Sigma \in \mathbb{R}^{n\times m}$ é uma matriz diagonal

retangular da forma

$$\Sigma = \begin{bmatrix} \sigma_1 & & & & & \\ & \sigma_2 & & & & \\ & & \ddots & & & \\ & & & \sigma_r & & \\ & & & & 0 & \\ & & & & & \ddots \end{bmatrix}, \qquad \sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0.$$

Os números $\sigma_1, \ldots, \sigma_r$ são chamados *valores singulares* de $A$ e são definidos como as raízes quadradas dos autovalores não nulos de $A^T A$. Considerando apenas os $k$ maiores valores singulares e seus respectivos vetores singulares, obtém-se a matriz $A_k = U_k \Sigma_k V_k^T$, que aproxima $A$ com $\text{posto}(A_k) = k$.

### 3.1 Demonstração

Seja $A \in \mathbb{R}^{n \times m}$ com $\text{posto}(A) = r$. A matriz $A^T A \in \mathbb{R}^{m \times m}$ é simétrica e semidefinida positiva. Pelo Teorema Espectral para matrizes simétricas, existe uma base ortonormal de autovetores $v_1, v_2, \ldots, v_m \in \mathbb{R}^m$ associados aos autovalores reais $\lambda_1, \lambda_2, \ldots, \lambda_m$, ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > \lambda_{r+1} = \cdots = \lambda_m = 0.$$

Como $\lambda_i \geq 0$ para todo $i$, definimos os valores singulares de $A$ por $\sigma_i = \sqrt{\lambda_i}$. Para as componentes não nulas ($i \leq r$), temos $\sigma_i > 0$. Agrupando os autovetores, formamos a matriz ortogonal $V = [v_1 \; v_2 \; \ldots \; v_m] \in \mathbb{R}^{m \times m}$. Para os índices $i, j \leq r$, a ortonormalidade dos vetores implica que

$$(Av_i)^T (Av_j) = v_i^T (A^T A v_j) = v_i^T (\lambda_j v_j) = \lambda_j (v_i^T v_j) = \begin{cases} \sigma_i^2, & \text{se } i = j, \\ 0, & \text{se } i \neq j. \end{cases}$$

Normalizando os vetores imagem para as $r$ primeiras componentes, definimos:

$$u_i = \frac{1}{\sigma_i} A v_i, \quad \text{para } i = 1, \ldots, r. \tag{2}$$

Por construção, o conjunto $\{u_1, \ldots, u_r\}$ é ortonormal em $\mathbb{R}^n$. Estendemos este conjunto até obter uma base ortonormal completa para $\mathbb{R}^n$, adicionando os vetores ortogonais $\{u_{r+1}, \ldots, u_n\}$, e organizando-os na matriz ortogonal $U = [u_1 \; u_2 \; \ldots \; u_n] \in \mathbb{R}^{n \times n}$.

Da definição em (2), decorre diretamente que $Av_i = \sigma_i u_i$ para $i \leq r$. Para $i > r$, como $\lambda_i = 0$, temos:

$$\|Av_i\|_2^2 = v_i^T A^T A v_i = v_i^T (0) = 0 \implies Av_i = 0.$$

Podemos expressar as relações para todas as colunas de $V$ como:

$$AV = A[v_1 \ \dots \ v_r \ v_{r+1} \ \dots \ v_m] = [\sigma_1 u_1 \ \dots \ \sigma_r u_r \ 0 \ \dots \ 0] = U\Sigma \implies AV = U\Sigma.$$

Como $V$ é ortogonal, sua inversa é igual à sua transposta ($V^{-1} = V^T$). Multiplicando a equação acima por $V^T$ à direita, isolamos a matriz $A$:

$$A = U\Sigma V^T,$$

o que encerra a demonstração da existência da fatoração.

## 4 Teorema de Eckart-Young

O teorema afirma que a melhor aproximação de posto $k$ para uma matriz $A$ é obtida truncando a sua SVD, mantendo apenas os $k$ maiores valores singulares e os vetores correspondentes.

Seja $A = U\Sigma V^T$ a decomposição em valores singulares de uma matriz $A \in \mathbb{R}^{n\times m}$ com $\text{posto}(A) = r$ e valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$. Para um inteiro $k < r$, definimos a truncagem da SVD de posto $k$ por

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^T,$$

onde $u_i$ e $v_i$ correspondem aos vetores singulares à esquerda e à direita associados ao valor singular $\sigma_i$.

Se $B \in \mathbb{R}^{n\times m}$ for qualquer outra matriz com $\text{posto}(B) \leq k$, o teorema estabelece que:

$$\text{i) Na norma espectral } (\|\cdot\|_2): \quad \|A - A_k\|_2 = \sigma_{k+1} \leq \|A - B\|_2,$$

$$\text{ii) Na norma de Frobenius } (\|\cdot\|_F): \quad \|A - A_k\|_F = \sqrt{\sum_{i=k+1}^{r} \sigma_i^2} \leq \|A - B\|_F.$$

### 4.1 Demonstração

#### 4.1.1 Cálculo da distância $\|A - A_k\|_2$

Definimos $A_k = U\Sigma_k V^T$, onde $\Sigma_k = \text{diag}\{\sigma_1, \dots, \sigma_k, 0, \dots, 0\}$. A diferença é dada por:

$$A - A_k = U(\Sigma - \Sigma_k)V^T.$$

A matriz diagonal $(\Sigma - \Sigma_k)$ possui elementos $\{0, \dots, 0, \sigma_{k+1}, \dots, \sigma_r, 0, \dots, 0\}$. O maior valor singular desta diferença é $\sigma_{k+1}$. Como a norma espectral de uma matriz é igual ao seu maior valor singular, temos $\|A - A_k\|_2 = \sigma_{k+1}$.

### 4.1.2 Prova da Minimalidade

Seja $B$ qualquer matriz com $\text{posto}(B) \leq k$. Devemos mostrar que $\|A - B\|_2 \geq \sigma_{k+1}$. Considere o espaço nulo de $B$, $\mathcal{N}(B)$. Pelo Teorema do Posto-Nulidade:

$$\dim(\mathcal{N}(B)) \geq m - k.$$

Considere o subespaço $S = \text{span}\{v_1, \ldots, v_{k+1}\}$, em que os $v_i$ são os vetores singulares à direita de $A$. A dimensão de $S$ é $k + 1$. Como a soma das dimensões satisfaz:

$$\dim(\mathcal{N}(B)) + \dim(S) \geq (m - k) + (k + 1) = m + 1,$$

deve haver uma interseção não trivial entre os dois subespaços. Existe, portanto, um vetor unitário $\hat{x}$ tal que $\hat{x} \in \mathcal{N}(B) \cap S$ e $\|\hat{x}\|_2 = 1$. Por estar no espaço nulo de $B$, temos $B\hat{x} = 0$. Por estar em $S$, podemos escrever $\hat{x} = \sum_{i=1}^{k+1} c_i v_i$ com $\sum |c_i|^2 = 1$. Assim, $(A - B)\hat{x} = A\hat{x} = \sum_{i=1}^{k+1} \sigma_i c_i u_i$. Calculando a norma ao quadrado (pela ortonormalidade dos $u_i$):

$$\|(A - B)\hat{x}\|_2^2 = \sum_{i=1}^{k+1} \sigma_i^2 |c_i|^2 \geq \sigma_{k+1}^2 \sum_{i=1}^{k+1} |c_i|^2 = \sigma_{k+1}^2.$$

Pela definição da norma induzida, temos $\|A - B\|_2 \geq \|(A - B)\hat{x}\|_2 \geq \sigma_{k+1}$. Isso prova que $A_k$ é a melhor aproximação possível em relação à norma espectral.

## 5 Decomposição em Soma de Matrizes de Posto Um

Outra consequência da SVD é a possibilidade de escrever uma matriz como a soma de matrizes de posto $1$. De fato, se $A = U\Sigma V^T$, então:

$$A = \sum_{i=1}^{r} \sigma_i u_i v_i^T,$$

em que cada termo $\sigma_i u_i v_i^T$ é uma matriz de posto $1$, denominada componente singular da matriz $A$.

Essa decomposição mostra que a matriz da imagem pode ser separada em várias partes mais simples, organizadas de acordo com sua relevância. As componentes associadas aos maiores valores singulares carregam as informações mais expressivas da imagem, enquanto as componentes de menores valores singulares representam detalhes sutis e pequenas variações. Esse comportamento permite comprimir a imagem mantendo apenas as componentes mais importantes e descartando as de menor magnitude, obtendo assim uma boa aproximação da imagem original com um volume reduzido de dados.

## 6 Aplicação e Implementação

Ao representar uma imagem por uma matriz em que cada $a_{ij}$ representa a intensidade do pixel, no caso de imagens em tons de cinza, cada pixel recebe um valor inteiro no intervalo $[0, 255]$, que é normalizado para o intervalo $[0, 1]$. Nesse caso, o valor $0$ corresponde ao preto e o valor $1$ ao branco. Dessa forma, a imagem é modelada por uma matriz $A \in \mathbb{R}^{n \times m}$, onde $n$ e $m$ representam a dimensão de pixels da imagem. Para imagens coloridas, a imagem é decomposta em três matrizes independentes, isto é, cada pixel $a_{ij}$ é representado por um vetor da forma $a_{ij} = (r, g, b)$.

As ilustrações a seguir, geradas em Python, exemplificam essa modelagem matricial:

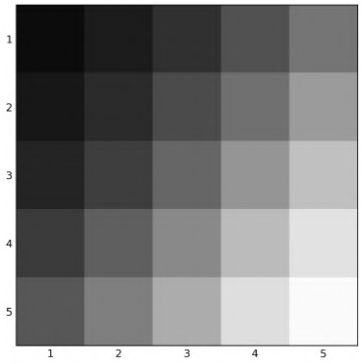



Imagem em escala de cinza

$$A = \begin{bmatrix} 0 & 18 & 042 & 75 & 110 \\ 12 & 035 & 68 & 105 & 148 \\ 28 & 55 & 95 & 142 & 185 \\ 52 & 88 & 130 & 180 & 220 \\ 80 & 120 & 165 & 215 & 255 \end{bmatrix}$$

Matriz associada

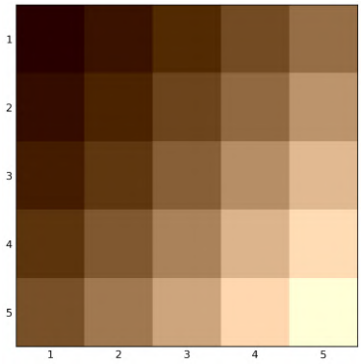



Imagem colorida

$$A^{(R)} = \begin{bmatrix} 40 & 58 & 82 & 115 & 150 \\ 52 & 75 & 108 & 145 & 188 \\ 68 & 95 & 135 & 182 & 225 \\ 92 & 128 & 170 & 220 & 255 \\ 120 & 160 & 205 & 255 & 255 \end{bmatrix}$$

$$A^{(G)} = \begin{bmatrix} 0 & 18 & 42 & 75 & 110 \\ 12 & 35 & 68 & 105 & 148 \\ 28 & 55 & 95 & 142 & 185 \\ 52 & 88 & 130 & 180 & 220 \\ 80 & 120 & 165 & 215 & 255 \end{bmatrix}$$

$$A^{(B)} = \begin{bmatrix} 0 & 0 & 2 & 35 & 70 \\ 0 & 0 & 28 & 65 & 108 \\ 0 & 15 & 55 & 102 & 145 \\ 12 & 48 & 90 & 140 & 180 \\ 40 & 80 & 125 & 175 & 215 \end{bmatrix}$$

Matrizes associadas

## 6.1 Implementação

A SVD completa de uma matriz $A \in \mathbb{R}^{n\times m}$ requer o armazenamento de $(n\times n)+\min(n,m)+(m\times m)$ valores. Isso nos obriga a truncar em um posto $k$ tal que:

$$nk + k + km < n^2 + \min(n, m) + m^2$$

para haver compressão real. Ao truncar uma matriz $A \in \mathbb{R}^{n\times m}$ em um posto $k$, obtém-se $A_k = U_k\Sigma_k V_k^T$, onde $U_k \in \mathbb{R}^{n\times k}$, $\Sigma_k \in \mathbb{R}^{k\times k}$ e $V_k^T \in \mathbb{R}^{k\times m}$. A matriz reconstruída $A_k \in \mathbb{R}^{n\times m}$ possui a mesma dimensão de $A$, porém comprimida. A taxa de compressão é definida por:

$$CR = \frac{T_{\text{SVD}}}{T_{\text{original}}}, \tag{3}$$

onde $T_{\text{SVD}}$ representa o tamanho da representação truncada e $T_{\text{original}}$ é o tamanho ocupado pela imagem original em disco.

O código implementado determina $k_{\text{max}}$ a partir do tamanho real da representação truncada armazenada em disco, sendo também possível obter esse valor teoricamente. Considerando uma imagem de dimensão $n \times m$, armazenada com $b$ bits por pixel, e uma representação SVD truncada cujos coeficientes são armazenados em precisão de $p$ bytes por número, o tamanho da imagem original é dado por:

$$T_{\text{original}} = nm\frac{b}{8}.$$

A representação de posto $k$ necessita armazenar as matrizes $U_k$, $V_k$ e os $k$ valores singulares, totalizando $k(n + m + 1)$ coeficientes numéricos. Para cada valor singular eliminado de $\Sigma$, eliminam-se $(n + m + 1)$ valores na representação SVD. Assim, o tamanho teórico da SVD é $T_{\text{SVD}}(k) = k(n + m + 1)p$. Igualando os custos de armazenamento, obtém-se a estimativa para o ponto onde a taxa de compressão atinge $CR \approx 1$:

$$k_{\text{max}} = \left\lfloor \frac{nmb}{8p(n + m + 1)} \right\rfloor. \tag{4}$$

Para a implementação aplicada, adotando a precisão `float32` ($p = 4$) e $b = 8$ para imagens em escala de cinza de dimensão $674 \times 768$, o valor de $k_{\text{max}}$ é:

$$k_{\text{max}} = \left\lfloor \frac{674 \cdot 768}{4(674 + 768 + 1)} \right\rfloor \approx 89.$$

Abaixo são apresentados os exemplos visuais aplicados à imagem em escala de cinza:



(a) Imagem PB original

(b) Reconstrução em $k_{\text{max}}$.

Figura 1: Comparação entre a imagem em escala de cinza original e com $k_{\text{max}}$.
*Fonte: Foto registrada pelo autor.*

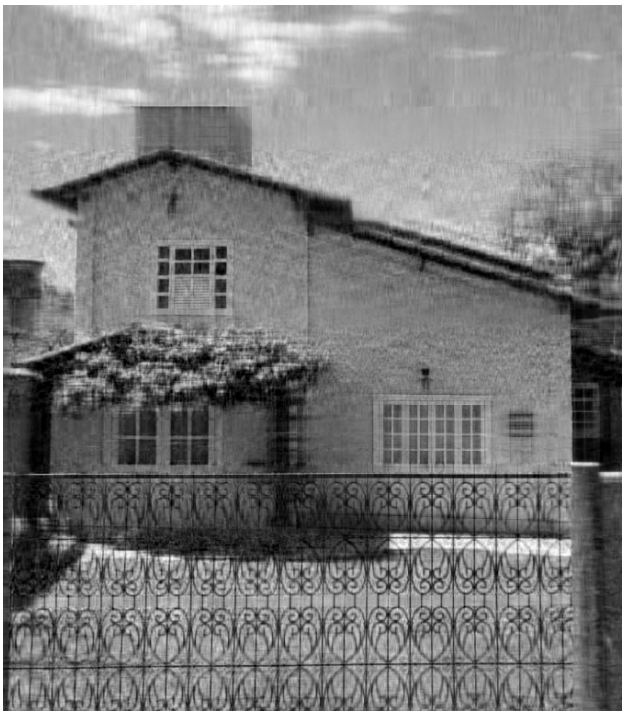
A partir da expressão

$$k^* = \frac{CR^* \, nm}{4(n+m+1)}, \tag{5}$$

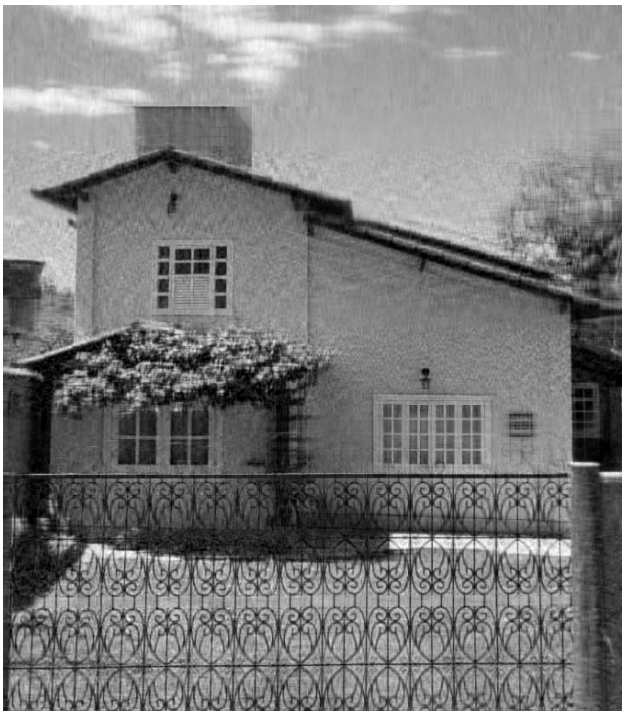
é possível determinar o posto correspondente a uma taxa de compressão desejada $CR^*$. Para este exemplo ($k_{\text{max}} = 89$), a relação se simplifica para $k^* = CR^* \cdot k_{\text{max}}$, resultando nos valores:

$$\begin{cases} k = 44 & \text{para } CR = 0{,}50, \\ k = 62 & \text{para } CR = 0{,}70, \\ k = 75 & \text{para } CR = 0{,}85, \\ k = 89 & \text{para } CR = 1{,}00. \end{cases} \tag{6}$$

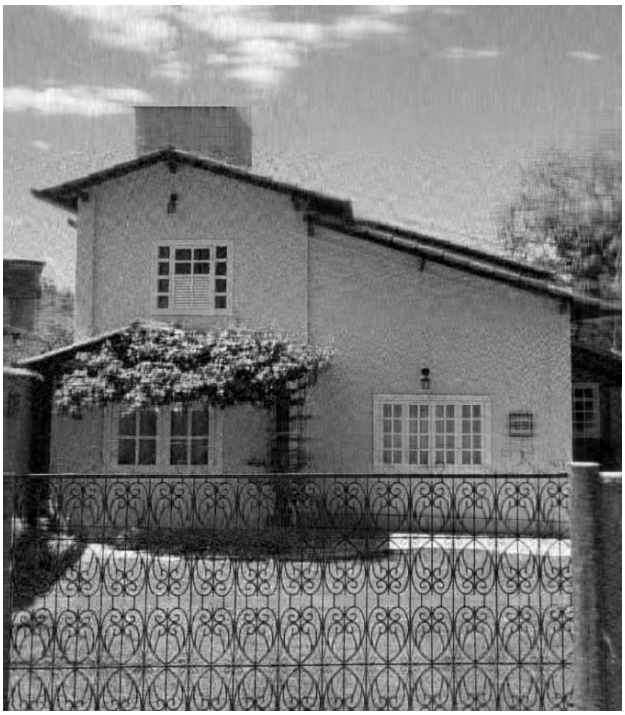
As reconstruções associadas a esses valores são apresentadas abaixo:



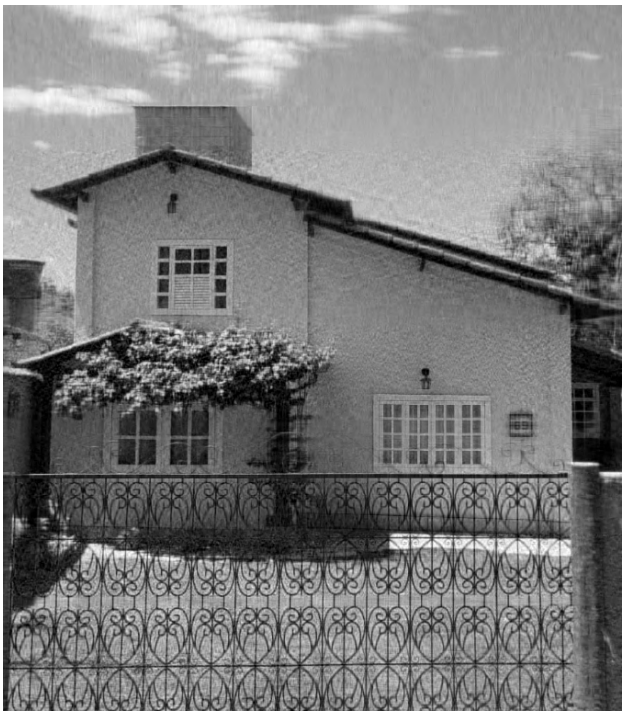
(a) $k = 44 \quad (CR \approx 0{,}50)$



(b) $k = 62 \quad (CR \approx 0{,}70)$



(c) $k = 75 \quad (CR \approx 0{,}85)$



(d) $k = 89 \quad (CR \approx 1{,}00)$

Figura 2: Mosaico de reconstruções em tons de cinza para diferentes postos $k$.

Para verificar o comportamento da decomposição SVD em imagens coloridas (RGB), o procedimento foi aplicado separadamente em cada canal.



(a) Imagem RGB original

(b) Reconstrução em $k_{\text{max}}$.

Figura 3: Comparação entre a imagem colorida original e com $k_{\text{max}}$.
*Fonte: Foto registrada pelo autor.*

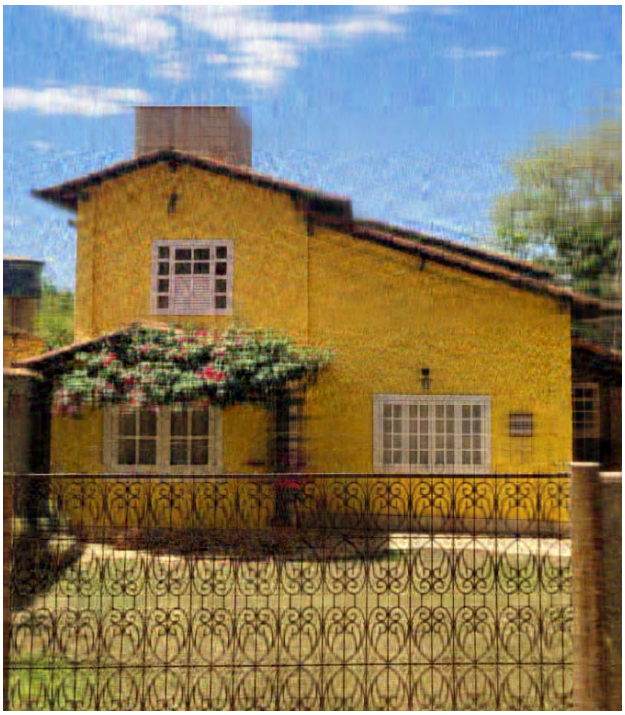
Considerando a precisão `float32` ($p = 4$), a taxa de compressão para a imagem colorida é dada por:

$$CR = \frac{3k(n+m+1)p}{3nm\frac{b}{8}} = \frac{8pk(n+m+1)}{nmb}.$$

Como a imagem original também possui três canais, o fator $3$ é cancelado no numerador e no denominador. Para $b = 8$ e $p = 4$, obtém-se novamente:

$$k = \frac{CR^* nm}{4(n+m+1)}.$$

Com isso, para a mesma dimensão, os valores obtidos são idênticos aos de (6), conforme ilustrado a seguir:



(a) $k = 44 \quad (CR \approx 0{,}50)$



(b) $k = 62 \quad (CR \approx 0{,}70)$



(c) $k = 75 \quad (CR \approx 0{,}85)$



(d) $k = 89 \quad (CR \approx 1{,}00)$

Figura 4: Mosaico de reconstruções coloridas para diferentes postos $k$.

## 6.2 Métricas de Qualidade

Para analisar a eficiência da compressão, foram utilizadas métricas quantitativas de qualidade da imagem reconstruída, da taxa de compressão e do erro relativo. O Erro Quadrático

Médio (MSE) mede o erro médio entre os pixels da imagem original e da reconstruída; a Razão Sinal-Ruído de Pico (PSNR) avalia a qualidade da reconstrução com base nesse erro; e a norma de Frobenius relativa mede a diferença global. Os resultados foram plotados graficamente em Python.

### 6.2.1 Mean Squared Error (MSE)

O erro quadrático médio mede a média dos quadrados das diferenças pixel a pixel entre a imagem original $A$ e a imagem reconstruída $A_k$:

$$MSE(A, A_k) = \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} (A_{ij} - A_{k,ij})^2. \tag{7}$$

Quanto menor o MSE, mais próxima a imagem reconstruída estará da original. Um valor igual a zero indica reconstrução idêntica.

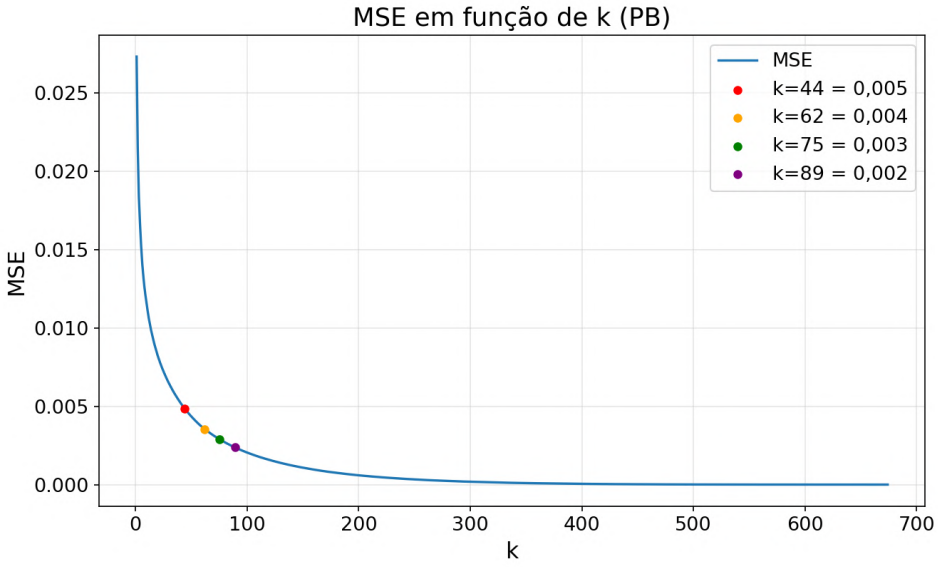



Figura 5: Curva do MSE para a imagem em tons de cinza.

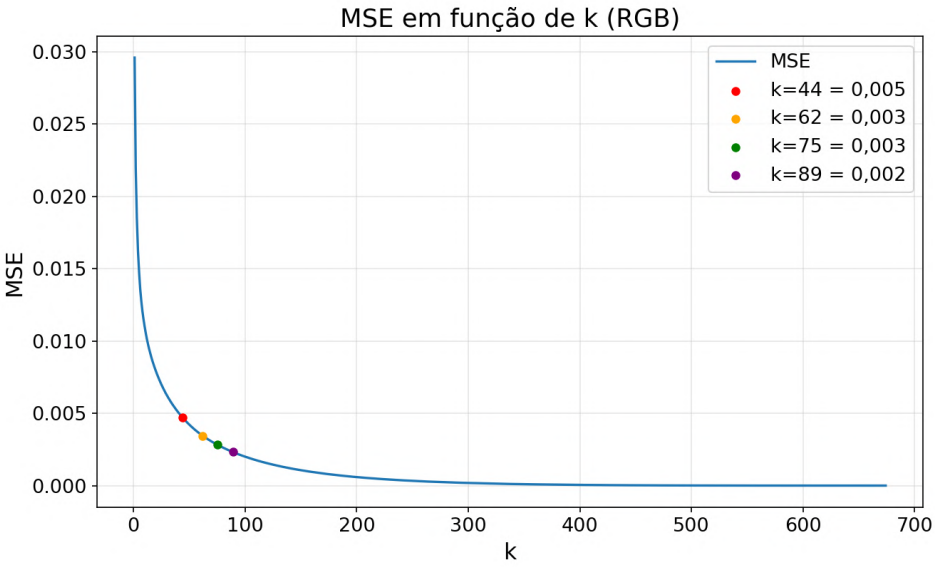



Figura 6: Curva do MSE para a imagem colorida.

### 6.2.2 Peak Signal-to-Noise Ratio (PSNR)

O PSNR mede a qualidade de reconstrução de uma imagem comprimida a partir do MSE:

$$PSNR(A, A_k) = 10 \log_{10} \left( \frac{MAX^2}{MSE(A, A_k)} \right), \tag{8}$$

onde $MAX$ é o valor máximo de intensidade do pixel (com $MAX = 1$ para dados normalizados).

Valores maiores de PSNR indicam melhor qualidade visual. Em geral:

$$\begin{cases} PSNR > 40 \text{ dB:} & \text{perda imperceptível;} \\ 30 \leq PSNR \leq 40 \text{ dB:} & \text{boa qualidade visual;} \\ PSNR < 30 \text{ dB:} & \text{degradação perceptível.} \end{cases}$$

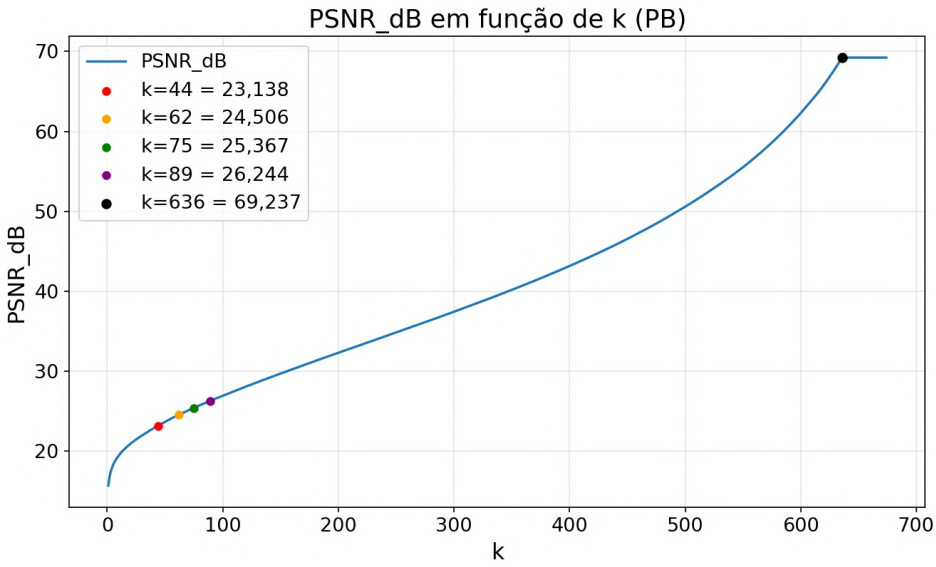



Figura 7: Curva do PSNR em dB para a imagem em tons de cinza.

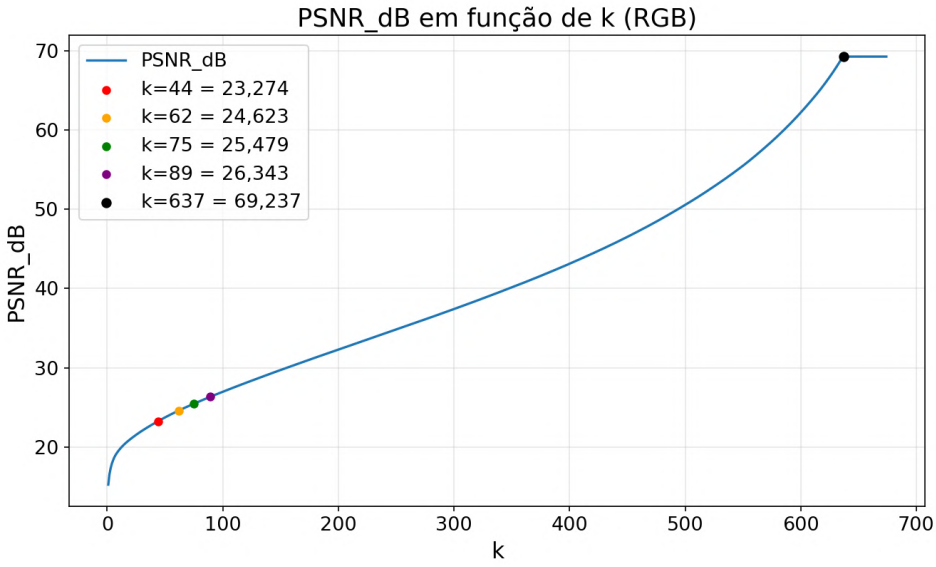



Figura 8: Curva do PSNR em dB para a imagem colorida.

A partir de determinado posto $k$ ($636$ para a imagem PB e $637$ para a imagem RGB), o PSNR permanece praticamente constante. Isso ocorre porque os valores singulares seguintes possuem uma contribuição desprezível dentro da precisão `float32` utilizada no algoritmo (ordem de $10^{-7}$). Assim, as variações adicionais no MSE e no PSNR tornam-se numericamente imperceptíveis.

### 6.2.3 Norma de Frobenius do erro

A norma de Frobenius do erro de reconstrução é definida por:

$$\|A - A_k\|_F = \sqrt{\sum_{i=1}^{n}\sum_{j=1}^{m}(A_{ij} - A_{k,ij})^2}. \tag{9}$$

Essa métrica indica a magnitude global do erro acumulado. Pelo Teorema de Eckart-Young, a matriz truncada $A_k$ minimiza essa quantidade entre todas as matrizes de posto menor ou igual a $k$. Além disso:

$$\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^{r}\sigma_i^2}, \tag{10}$$

mostrando que o erro depende diretamente da soma dos quadrados dos valores singulares descartados.

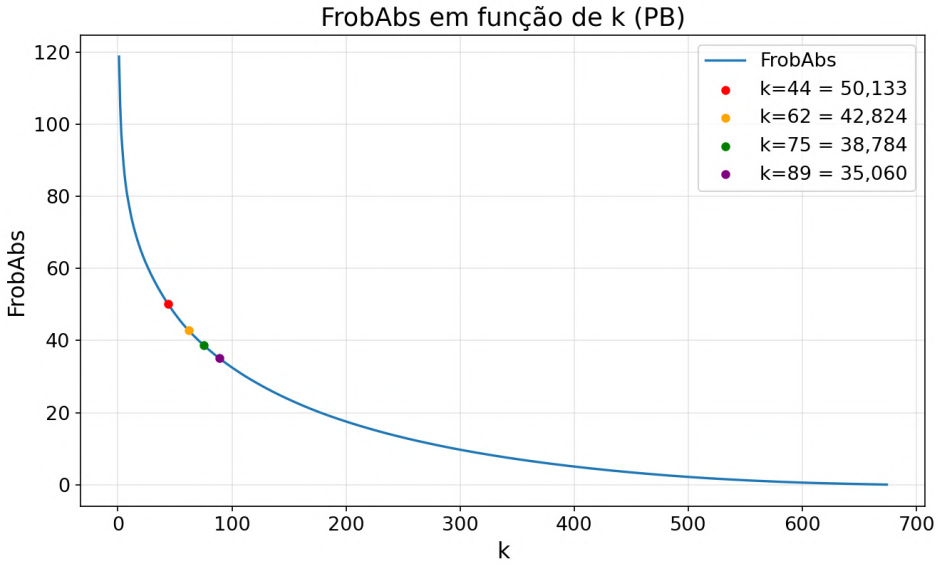



Figura 9: Erro na norma de Frobenius para a imagem em tons de cinza.

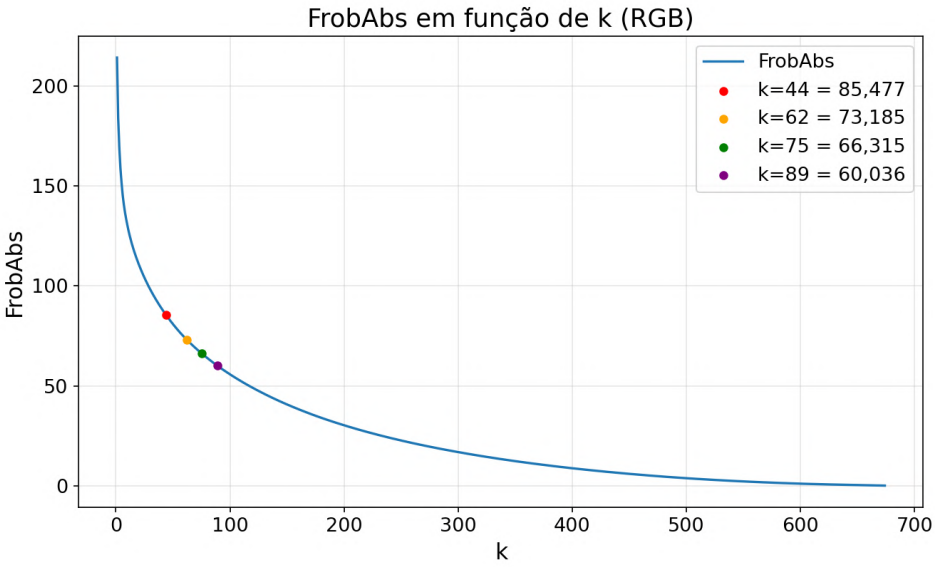



Figura 10: Erro na norma de Frobenius para a imagem colorida.

## 7 Considerações Finais

A compressão via Decomposição em Valores Singulares apresentou resultados satisfatórios, especialmente para as imagens de alta resolução testadas experimentalmente. Nos experimentos, foi possível obter aproximações visualmente e numericamente próximas da imagem original com um tamanho de armazenamento significativamente menor, sobretudo para valores baixos de $k$, nos quais a representação por meio da SVD mantém uma taxa de compressão bastante favorável sem comprometer a qualidade visual.

## Referências

[1] J. Bezanson, A. Edelman, S. Karpinski, and V. B. Shah. Julia: A fresh approach to numerical computing. *SIAM Review*, 59(1):65–98, 2017. v1.12.6.

[2] G. H. Golub and C. F. Van Loan. *Matrix computations*, volume 3. JHU press, 2013.

[3] R. C. Gonzalez and R. E. Woods. *Processamento de imagens digitais*. Editora Blucher, 2000.

[4] Python Software Foundation. *Python Language Reference, version 3.12.3*, 2024. Acessado em: 13 ago. 2026.

[5] D. S. Watkins. *Fundamentals of matrix computations*. John Wiley & Sons, 2004.

# CERTIFICADO

Certificamos que Matheus Henrique Gomes dos Santos participou, como ouvinte, do evento 22° CONPEEX, realizado pela Universidade Federal de Goiás, no período de 04 a 07 de novembro de 2025, com carga horária total de 40 hora(s).

Goiânia, 17 de novembro de 2025.

ADRIANA RÉGIA MARQUES DE SOUZA
Presidente da Comissão Científica do 22° Conpeex

LUANA CÁSSIA MIRANDA RIBEIRO
Coordenadora Geral do 22° Conpeex

Apoio

Realização

A autenticidade desde documento pode ser verificada por meio da URL: https://web.ufg.br/plateia-inscrito/#/validar-certificado/81b17e6bf08f83d3c4b64b2599341439

# CERTIFICADO

Certificamos que Matheus Henrique Gomes dos Santos participou, como ouvinte, da palestra Ciência no Calor do Cerrado, realizada no 22º Conpeex, no período de 05/11/2025, com carga horária total de 4 hora(s).

Goiânia, 17 de novembro de 2025.

ADRIANA RÉGIA MARQUES DE SOUZA
Presidente da Comissão Científica do 22° Conpeex

LUANA CÁSSIA MIRANDA RIBEIRO
Coordenadora Geral do 22° Conpeex

Apoio

Realização

A autenticidade desde documento pode ser verificada por meio da URL: https://web.ufg.br/plateia-inscrito/#/validar-certificado/b5bf432c39b320f8de7f86974277c688

CERTIFICADO

programa DIÁLOGOS EM PESQUISA E INOVAÇÃO

Certificamos que Matheus Henrique Gomes dos Santos participou do evento **"Pesquisa em biodiversidade na UFG: conhecendo a UPBio Prof. Rizzo",** atividade do **Programa Diálogos em Pesquisa e Inovação**, promovida pela **Pró-Reitoria de Pesquisa e Inovação** da **Universidade Federal de Goiás**, no dia **13 de Abril de 2026,** com **02 (duas) horas** de duração.

Goiânia, 06 de maio de 2026.

**Wendell Karlos Tomazelli Coltro**
*Pró-Reitor de Pesquisa e Inovação*

PRPI PRÓ-REITORIA DE PESQUISA E INOVAÇÃO

UFG UNIVERSIDADE FEDERAL DE GOIÁS

A autenticidade desde documento pode ser verificada por meio da URL: https://web.ufg.br/plateia-inscrito/#/validar-certificado/

CERTIFICADO

programa DIÁLOGOS EM PESQUISA E INOVAÇÃO

Certificamos que Matheus Henrique Gomes dos Santos participou do evento **"Ciência Aberta e seu impacto na pesquisa",** atividade do **Programa Diálogos em Pesquisa e Inovação**, promovida pela **Pró-Reitoria de Pesquisa e Inovação** da **Universidade Federal de Goiás**, no dia **05 de Maio de 2026,** com **02 (duas) horas** de duração.

Goiânia, 09 de junho de 2026.

**Wendell Karlos Tomazelli Coltro**
*Pró-Reitor de Pesquisa e Inovação*

PRPI PRÓ-REITORIA DE PESQUISA E INOVAÇÃO

UFG UNIVERSIDADE FEDERAL DE GOIÁS

A autenticidade desde documento pode ser verificada por meio da URL: https://web.ufg.br/plateia-INSCRITO/#/validar-certificado/