Compressão de Imagens via Decomposição em Valores Singulares

Matheus Henrique Gomes dos Santos[1], Leandro da Fonseca Prudente[2]

[1]Estudante, Instituto de Matemática e Estatística (IME), matheus_henrique2@discente.ufg.br
[2]Orientador, Instituto de Matemática e Estatística (IME), lfprudente@ufg.br

Resumo

A decomposição em valores singulares (SVD) é um método algébrico permite escrever uma matriz como $A = U\Sigma V^T$, onde Σ contém os valores singulares em ordem decrescente [4]. A compressão via SVD trunca esses valores, descartando os menores, resultando em uma aproximação de menor posto da matriz original [2]. A fim de estudar a compressão de dados, aplicamos isso a imagens digitais interpretando cada pixel como a_{ij} (escala de cinza) ou $a_{ij}^{(R)}$, $a_{ij}^{(G)}$, $a_{ij}^{(B)}$ (colorida). Implementamos a SVD em Júlia, reconstruímos aproximações da imagem e calculamos k_{max}, o ponto de truncagem onde a taxa de compressão *(Compression Ratio)* $CR \approx 1$ e avaliamos os valores para $k < k_{\text{max}}$, onde existe a compressão e medimos numericamente a qualidade da compressão por meio de PSNR, MSE e a norma de Frobenius do erro.

Palavras-chave:

Decomposição em Valores Singulares, posto, matriz, compressão, reconstrução

1 Apresentação

A compressão de dados é um problema central em processamento digital, o objetivo no caso de imagens consiste em reconstruir uma imagem com a menor quantidade de informações, preservando a qualidade visual e estrutural dela. Uma imagem em tons de cinza pode ser modelada por uma matriz $A \in \mathbb{R}^{n\times m}$, em que as entradas a_{ij} correspondem ao grau de tonalidade do pixel variando de preto a branco. De maneira análoga, uma imagem colorida pode ser decomposta como $A(R, G, B)$, onde cada canal representa a composição de cada cor (vermelho, verde e azul) no pixel da imagem. Essa matriz A pode ser escrita, pela decomposição em valores singulares, na forma $A = U\Sigma V^T$, em que $U \in \mathbb{R}^{n\times n}$ e $V \in \mathbb{R}^{m\times m}$ são matrizes ortogonais e $\Sigma \in \mathbb{R}^{n\times m}$ é uma matriz diagonal cujas entradas são os valores singulares de A, dispostos em ordem decrescente. A ideia da compressão SVD é substituir a matriz original por uma aproximação de posto menor, construída apenas com os maiores valores singulares. Para imagens coloridas teremos que aplicar a SVD para cada canal, mas truncando sempre em um mesmo posto para ambos, como valores pequenos e grandes ocupam

o mesmo espaço de armazenamento, descartar esses valores menores reduz a quantidade total de dados a serem armazenados sem uma perda visual significativa. A redução do posto é baseada na truncagem da matriz Σ e, como esta é uma matriz diagonal em que os valores estão definidos em ordem decrescente, não se corre o risco de descartar valores mais relevantes ao truncar ela, o que resguarda que não é necessário analisar nem verificar cada $\sigma_{ij}, \quad i = j > k$ eliminados, pois a própria definição garante que serão descartados valores menores em relação ao ponto k e o Teorema da SVD nos fornece que para $i \neq j, \sigma_{ij} = 0$.

O Teorema da Decomposição em Valores Singulares garante que toda matriz real pode ser fatorada em termos de bases ortogonais adequadas e uma matriz diagonal de valores não negativos e o Teorema de Eckart-Young mostra que a truncagem da SVD produz, entre todas as matrizes de posto limitado, a melhor aproximação possível da matriz original em normas naturais, como a norma de Frobenius e a norma espectral. Para analisar esse comportamento, abordamos a formulação teórica da decomposição e sua aplicação à compressão de imagens, utlizando medidas quantitativas de erro de reconstrução, como o *Mean Squared Error* (MSE), o *Peak Signal-to-Noise Ratio* (PSNR) e a norma de Frobenius do erro de reconstrução que nos permitem comparar diferentes valores de truncagem e analisar a diferença da compressão e a qualidade da imagem reconstruída já que a avaliação exclusivamente visual é empírica e subjetiva.

2 Teorema Decomposição em Valores Singulares (SVD)

Considere uma matriz $A \in \mathbb{R}^{n\times m}$, a decomposição em valores singulares nos dá que podemos representar essa matriz a partir de duas matrizes ortogonais e uma matriz diagonal com valores $\sigma_{ij} \neq 0$ se $i = j$ e $\sigma_{ij} = 0$ se $i \neq j$ que são os valores singulares de A. Essa representação é apresentada no seguinte teorema:

Seja $A \in \mathbb{R}^{n\times m}$ uma matriz não nula com posto(r). Então A pode ser expressa como um produto

$$A = U\Sigma V^T, \tag{1}$$

onde $U \in \mathbb{R}^{n\times n}$ e $V \in \mathbb{R}^{m\times m}$ são matrizes ortogonais, e $\Sigma \in \mathbb{R}^{n\times m}$ é uma matriz diagonal retangular da forma

$$\Sigma = \begin{bmatrix} \sigma_1 & & & & & \\ & \sigma_2 & & & & \\ & & \ddots & & & \\ & & & \sigma_r & & \\ & & & & 0 & \\ & & & & & \ddots \end{bmatrix}, \qquad \sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0.$$

Os números $\sigma_1, \ldots, \sigma_r$ são chamados *valores singulares* de A e são definidos como as raízes quadradas dos autovalores não nulos de A^TA, considerando apenas os k maiores valores singulares e os vetores singulares, obtemos uma matriz $A_k = U_k\Sigma_k V_k^T$, que aproxima A com posto(k). [4]

2.1 Demonstração

Seja $A \in \mathbb{R}^{n\times m}$ com posto$(A) = r$. A matriz $A^TA \in \mathbb{R}^{m\times m}$ é simétrica e semidefinida positiva. Pelo Teorema Espetral para matrizes simétricas, existe uma base ortonormal de autovetores $v_1, v_2, \ldots, v_m \in \mathbb{R}^m$ associados aos autovalores reais $\lambda_1, \lambda_2, \ldots, \lambda_m$, ordenados de modo que

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > \lambda_{r+1} = \cdots = \lambda_m = 0.$$

Como $\lambda_i \geq 0$ para todo i, definimos os valores singulares de A por $\sigma_i = \sqrt{\lambda_i}$. Para as componentes não nulas ($i \leq r$), temos $\sigma_i > 0$. Agrupando os autovetores, formamos a matriz ortogonal $V = [v_1\ v_2\ \ldots\ v_m] \in \mathbb{R}^{m\times m}$, para os índices $i, j \leq r$, a ortonormalidade dos vetores implica que

$$(Av_i)^T(Av_j) = v_i^T(A^TAv_j) = v_i^T(\lambda_j v_j) = \lambda_j(v_i^Tv_j) = \begin{cases} \sigma_i^2, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}$$

Normalizando os vetores imagem para as r primeiras componentes, definimos:

$$u_i = \frac{1}{\sigma_i}Av_i, \quad \text{para } i = 1, \ldots, r. \tag{2}$$

Por construção, o conjunto $\{u_1, \ldots, u_r\}$ é ortonormal em $\mathbb{R}^n$, estendemos este conjunto até obter uma base ortonormal completa para $\mathbb{R}^n$, adicionando vetores ortogonais $\{u_{r+1}, \ldots, u_n\}$, organizando-os na matriz ortogonal $U = [u_1\ u_2\ \ldots\ u_n] \in \mathbb{R}^{n\times n}$.

Da definição em (2), decorre diretamente que $Av_i = u_i\sigma_i$ para $i \leq r$ e $\lambda_i = 0$ para a $i > r$, o que implica

$$\|Av_i\|_2^2 = v_i^TA^TAv_i = v_i^T(0) = 0 \implies Av_i = 0$$

Podemos expressar as relações para todas as colunas de V como:

$$AV = A[v_1\ \ldots\ v_r\ v_{r+1}\ \ldots\ v_m] = [u_1\sigma_1\ \ldots\ u_r\sigma_r\ 0\ \ldots\ 0] = U\Sigma \implies AV = U\Sigma$$

Como V é uma matriz ortogonal, sua inversa é igual a sua transposta, isto é, $V^{-1} = V^T$. Multiplicando a equação acima por V^T à direita, isolamos a matriz A, obtemos

$$A = U\Sigma V^T \quad (1),$$

o que encerra a demonstração da existência da fatoração.

3 Teorema de Eckart-Young

O teorema afirma que a melhor aproximação de posto k para uma matriz A é obtida truncando a sua SVD mantendo apenas os k maiores valores singulares e os vetores correspondentes.

Seja $A = U\Sigma V^T$ a decomposição em valores singulares de uma matriz $A \in \mathbb{R}^{n\times m}$ com posto$(A) = r$ e valores singulares $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$. Para um inteiro $k < r$, definimos a truncagem da SVD de posto(k) por

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^T$$

onde u_i e v_i correspondem aos vetores singulares à esquerda e à direita associados ao valor singular σ_i.

Se $B \in \mathbb{R}^{n\times m}$ for qualquer outra matriz com posto$(B) \leq k$, o teorema estabelece que:

i) Na norma espectral ($\|\cdot\|_2$): $\|A - A_k\|_2 = \sigma_{k+1} \leq \|A - B\|_2$

ii) Na norma de Frobenius ($\|\cdot\|_F$): $\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^{r} \sigma_i^2} \leq \|A - B\|_F$ [2]

Demonstração:

3.1 Cálculo da distância $\|A - A_k\|_2$

Definimos $A_k = U\Sigma_k V^T$, onde $\Sigma_k = \text{diag}\{\sigma_1, \ldots, \sigma_k, 0, \ldots, 0\}$. A diferença é dada por:

$$A - A_k = U(\Sigma - \Sigma_k)V^T$$

A matriz diagonal $(\Sigma - \Sigma_k)$ possui elementos $\{0, \ldots, 0, \sigma_{k+1}, \ldots, \sigma_r, 0, \ldots, 0\}$. O maior valor singular desta diferença é σ_{k+1}. Como a norma espectral de uma matriz é igual ao seu maior valor singular, temos $\|A - A_k\|_2 = \sigma_{k+1}$

3.2 Prova da Minimalidade

Seja B qualquer matriz com posto$(B) \leq k$. Devemos mostrar que $\|A - B\|_2 \geq \sigma_{k+1}$.

Considere o espaço nulo de B, $\mathcal{N}(B)$. Pelo teorema do posto-nulidade,

$$\dim(\mathcal{N}(B)) \geq m - k.$$

Considere o subespaço $S = \text{span}\{v_1, \ldots, v_{k+1}\}$, onde os v_i são os vetores singulares à direita de A. A dimensão de S é $k + 1$. Como a soma das dimensões

$$\dim(\mathcal{N}(B)) + \dim(S) \geq (m - k) + (k + 1) = m + 1,$$

deve haver uma interseção não trivial entre os dois subespaços. Existe, portanto, um vetor

unitário $\hat{x}$ tal que $\hat{x} \in \mathcal{N}(B) \cap S$ e $\|\hat{x}\|_2 = 1$. Por estar no espaço nulo de B, temos $B\hat{x} = 0$. Por estar em S, podemos escrever $\hat{x} = \sum_{i=1}^{k+1} c_i v_i \quad$ com $\quad \sum |c_i|^2 = 1$, assim:

$$(A - B)\hat{x} = A\hat{x} = \sum_{i=1}^{k+1} \sigma_i c_i u_i$$

Calculando a norma ao quadrado (pela ortonormalidade de u_i):

$$\|(A - B)\hat{x}\|_2^2 = \sum_{i=1}^{k+1} \sigma_i^2 |c_i|^2 \geq \sigma_{k+1}^2 \sum_{i=1}^{k+1} |c_i|^2 = \sigma_{k+1}^2$$

pela definição da norma induzida: $\quad \|A - B\|_2 \geq \|(A - B)\hat{x}\|_2 \geq \sigma_{k+1}$. Isso prova que A_k é a melhor aproximação possível em relação à norma espectral.

4 Decomposição em Soma de Matrizes de Posto Um

Outra consequência da SVD é a possibilidade de escrever uma matriz como soma de matrizes de posto(1). De fato, se $A = U\Sigma V^T$, então $A = \sum_{i=1}^{r} \sigma_i u_i v_i^T$, cada termo $\sigma_i u_i v_i^T$ é uma matriz de posto(1), chamada componente singular da matriz A.

Essa decomposição mostra que a matriz da imagem pode ser separada em várias partes mais simples, organizadas de acordo com sua importância. As componentes associadas aos maiores valores singulares carregam as informações de mais valor da imagem, já as componentes de menores valores singulares representam detalhes menos perceptíveis e de pequenas variações, o que nos permite comprimir a imagem mantendo apenas as componentes mais importantes e descartando as de menores valores e consequentemente carregando menos informações e uma boa aproximação da imagem original.

5 Aplicação e implementação

Ao represertar uma imagem por uma matriz em que cada a_{ij} representa a tonalidade de cor de cada pixel, no caso de imagens em tons de cinza, cada pixel recebe um valor inteiro no intervalo $[0, 255]$, que pode ser normalizado para o intervalo $[0, 1]$. Nesse caso, o valor 0 corresponde ao preto e o valor 1 ao branco. Dessa forma, a imagem pode ser modelada por uma matriz $A \in \mathbb{R}^{n \times m}$, onde n e m representam, respectivamente, o número de linhas e colunas da matriz vinculada a imagem, ou seja, a dimensão de pixels da imagem. Para imagens coloridas, a imagem é decomposta em três matrizes independentes, isto é, cada pixel a_{ij} é representado por um vetor da forma $a_{ij} = (r, g, b)$.

Um exemplo simples da modelagem da imagem em matriz:

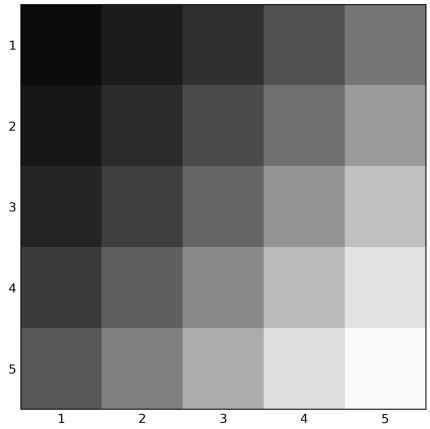


Imagem em escala de cinza

$$A = \begin{bmatrix} 0 & 18 & 042 & 75 & 110 \\ 12 & 035 & 68 & 105 & 148 \\ 28 & 55 & 95 & 142 & 185 \\ 52 & 88 & 130 & 180 & 220 \\ 80 & 120 & 165 & 215 & 255 \end{bmatrix}$$

Matriz associada

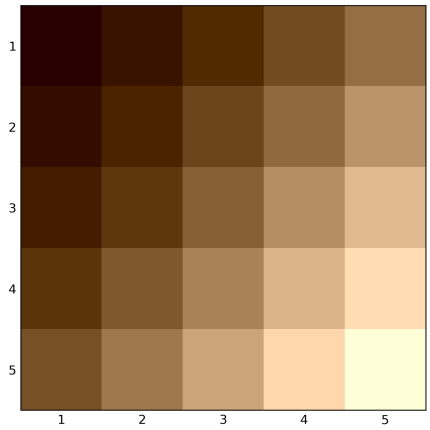


Imagem colorida

$$A^{(R)} = \begin{bmatrix} 40 & 58 & 82 & 115 & 150 \\ 52 & 75 & 108 & 145 & 188 \\ 68 & 95 & 135 & 182 & 225 \\ 92 & 128 & 170 & 220 & 255 \\ 120 & 160 & 205 & 255 & 255 \end{bmatrix}$$

$$A^{(G)} = \begin{bmatrix} 000 & 018 & 042 & 075 & 110 \\ 012 & 035 & 068 & 105 & 148 \\ 028 & 055 & 095 & 142 & 185 \\ 052 & 088 & 130 & 180 & 220 \\ 080 & 120 & 165 & 215 & 255 \end{bmatrix}$$

$$A^{(B)} = \begin{bmatrix} 000 & 000 & 002 & 035 & 070 \\ 000 & 000 & 028 & 065 & 108 \\ 000 & 015 & 055 & 102 & 145 \\ 012 & 048 & 090 & 140 & 180 \\ 040 & 080 & 125 & 175 & 215 \end{bmatrix}$$

Matrizes associadas

5.1 Implementação

A SVD completa de uma matriz $A \in \mathbb{R}^{n\times m}$ requer o armazenamento de $(n\times n)+\min(n,m)+(m\times m)$ valores, isso nos obriga a truncar em um posto(k) tal que

$$nk + k + km < n^2 + \min(n,m) + m^2.$$

para haver compressão real. Ao truncar uma matriz $A^{n\times m}$ que representa uma imagem em um posto(k), temos $A_k = U_k\Sigma_k V_k^T$, onde $U_k \in \mathbb{R}^{n\times k}$, $\Sigma_k \in \mathbb{R}^{k\times k}$ e $V_k^T \in \mathbb{R}^{k\times m}$, ou

seja, $A_k \in \mathbb{R}^{n\times m}$ possui a mesma dimensão de A, porém comprimida, com isso temos que a taxa de compressão é definida por

$$CR = \frac{T_{\text{SVD}}}{T_{\text{original}}}, \tag{3}$$

onde T_{SVD} representa o tamanho da representação truncada e T_{original} o tamanho da imagem original ocupados no disco

O código implementado determina k_{max} a partir do tamanho real da representação truncada armazenada em disco, porém é possível obter esse valor de maneira teórica. Considerando uma imagem com dimensão $n \times m$, armazenada com b bits por pixel, e uma representação SVD truncada cujos coeficientes são armazenados em precisão de p bytes por número, o tamanho da imagem original é calculado como:

$$T_{\text{original}} = nm\frac{b}{8}.$$

A representação de posto k necessita armazenar as matrizes U_k, V_k e os k valores singulares, totalizando $k(n+m+1)$ coeficientes numéricos, podemos interpretar a partir disso que para cada valor singular eliminado da matriz Σ, eliminamos $(n+m+1)$ valores dentro da SVD, essa seria nossa redução de armazenamento, isto é, a velocidade que compressão atua no decomposição. Assim, o tamanho teórico da SVD é $T_{\text{SVD}}(k) = k(n+m+1)p$. Igualando os dois custos de armazenamento, obtém-se uma estimativa para o ponto onde a taxa de compressão $CR \approx 1$:

$$k_{\text{max}} = \left\lfloor \frac{nmb}{8p(n+m+1)} \right\rfloor. \tag{4}$$

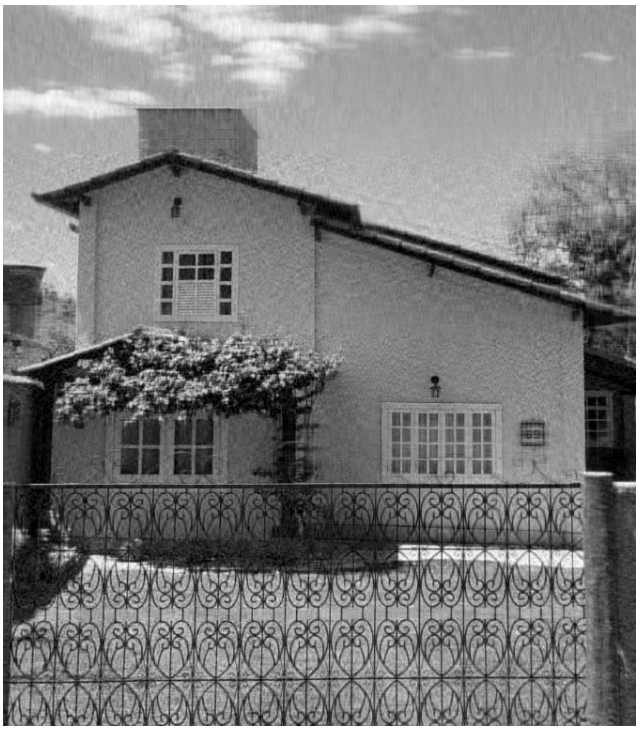
Para a implementação aplicada, adotando a precisão `float32`, para a qual $p = 4$, e para imagens em escala de cinza $b = 8$, utilizamos uma imagem de dimensão 674×768. O k_{max} desse exemplo é:

$$k_{\text{max}} = \left\lfloor \frac{674 \cdot 768}{4(674+768+1)} \right\rfloor \approx 89.$$

A seguir, os exemplos visuais aplicados na imagem em escala de cinza (PB):



(a) Imagem PB não comprimida



(b) Reconstrução em k_{max}.

A partir da expressão

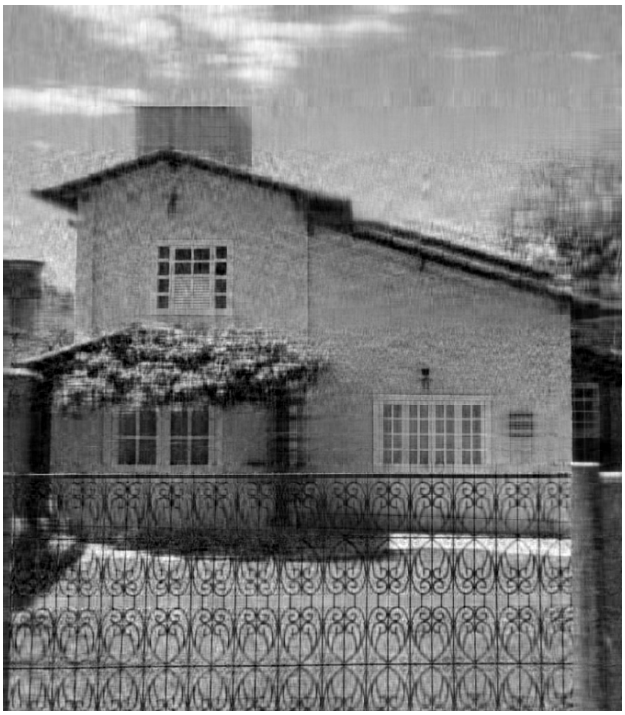
$$k^* = \frac{CR^* \, nm}{4(n+m+1)} \tag{5}$$

podemos determinar o posto correspondente a uma taxa de compressão desejada CR^*. Para a imagem utilizada neste exemplo, como já temos $k_{\text{max}} = 89$, podemos reduzir a expressão a:

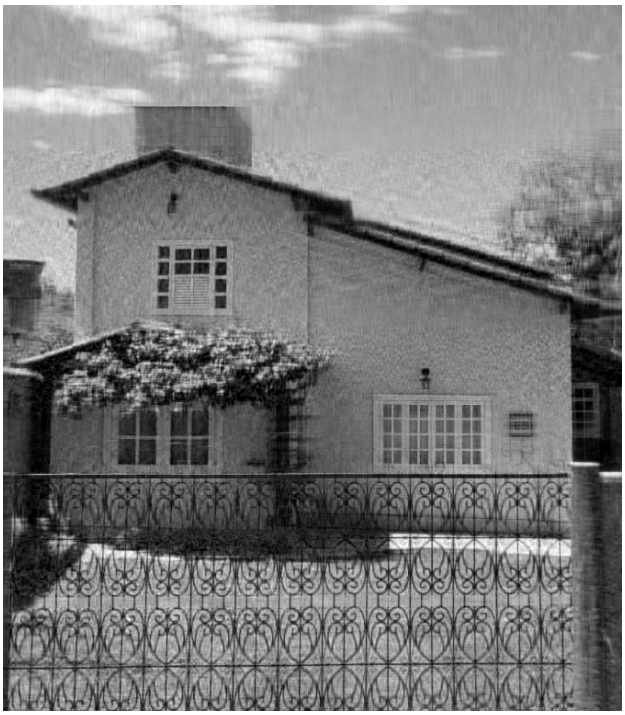
$$k^* = CR^* \cdot k_{\text{max}}$$

$$\begin{cases} k = 44 & \text{para } CR = 0{,}50 \\ k = 62 & \text{para } CR = 0{,}70 \\ k = 75 & \text{para } CR = 0{,}85 \\ k = 89 & \text{para } CR = 1{,}00 \end{cases} \tag{6}$$

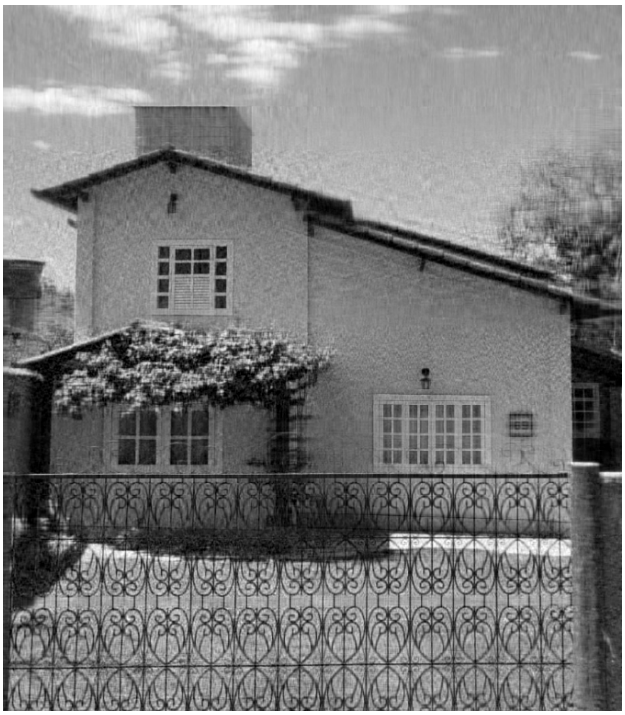
As reconstruções associadas a esses valores são apresentadas a abaixo:



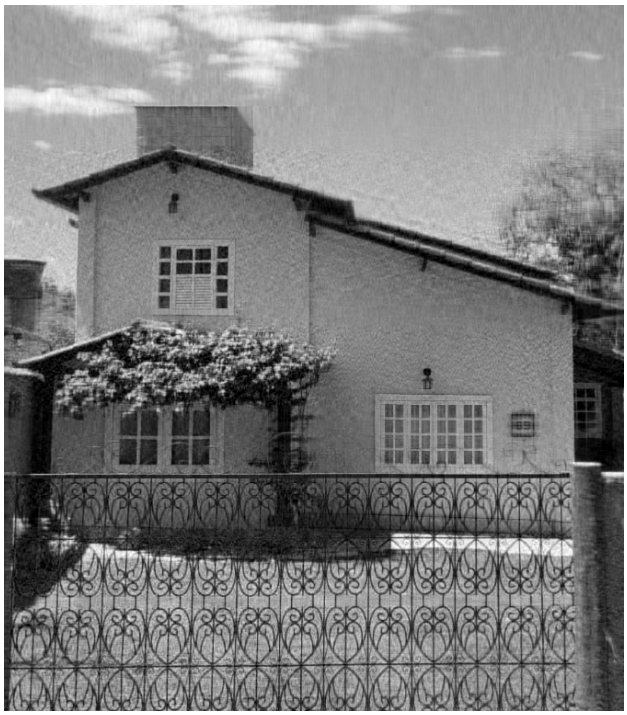
(a) $k = 44 \quad CR \approx 0,50$



(b) $k = 62 \quad CR \approx 0,70$



(c) $k = 75 \quad CR \approx 0,85$



(d) $k = 89 \quad CR \approx 1,00$

Para verificar o comportamento da decomposição SVD em imagens coloridas (RGB), foi realizado o mesmo procedimento separadamente para cada canal.



(a) Imagem RGB não comprimida



(b) Reconstrução em k_{max}.

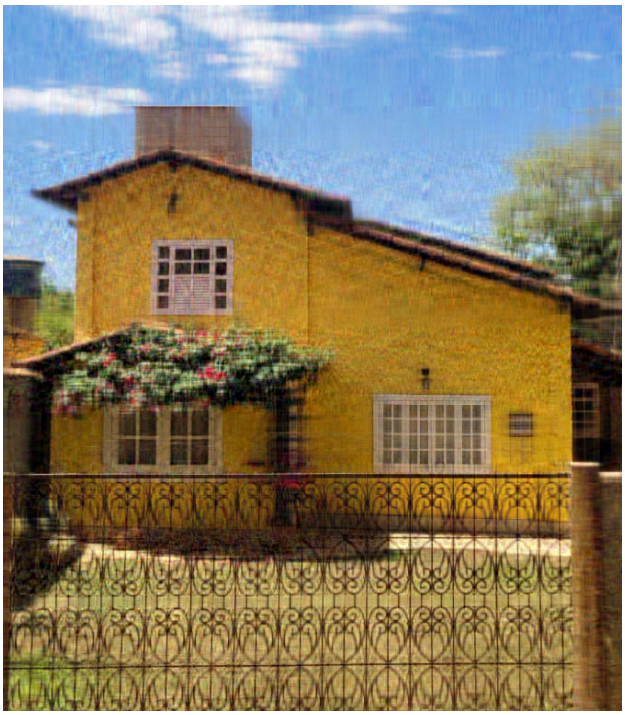
Considerando novamente a precisão `float32`, com $p = 4$, a taxa de compressão para a imagem colorida é dada por

$$CR = \frac{3k(n+m+1)p}{3nm\frac{b}{8}} = \frac{8pk(n+m+1)}{nmb}.$$

Como a imagem original também possui três canais, o número 3 aparece tanto no numerador quanto no denominador e, portanto, é cancelado. Dessa forma, para $b = 8$ e $p = 4$, obtemos novamente

$$k = \frac{CR^* nm}{4(n+m+1)}.$$

Assim, para a mesma dimensão e os mesmos valores de CR^* da imagem PB, os valores de k são iguais aos obtidos em (6). Com isso, temos a aplicação na imagem colorida a seguir:



(a) $k = 44 \quad CR \approx 0,5$



(b) $k = 62 \quad CR \approx 0,7$



(c) $k = 75 \quad CR \approx 0,85$



(d) $k = 89 \quad CR \approx 1,0$

5.2 Métricas de qualidade

Para podermos analisar a eficiência da compressão, foram utilizadas métricas quantitativas para a avaliar a qualidade da imagem reconstruída, da taxa de compressão e do erro relativo em relação à imagem original. O Erro Quadrático Médio (MSE) foi utilizado para medir o erro médio entre os pixels da imagem original e da reconstruída; o Pico da Razão Sinal-

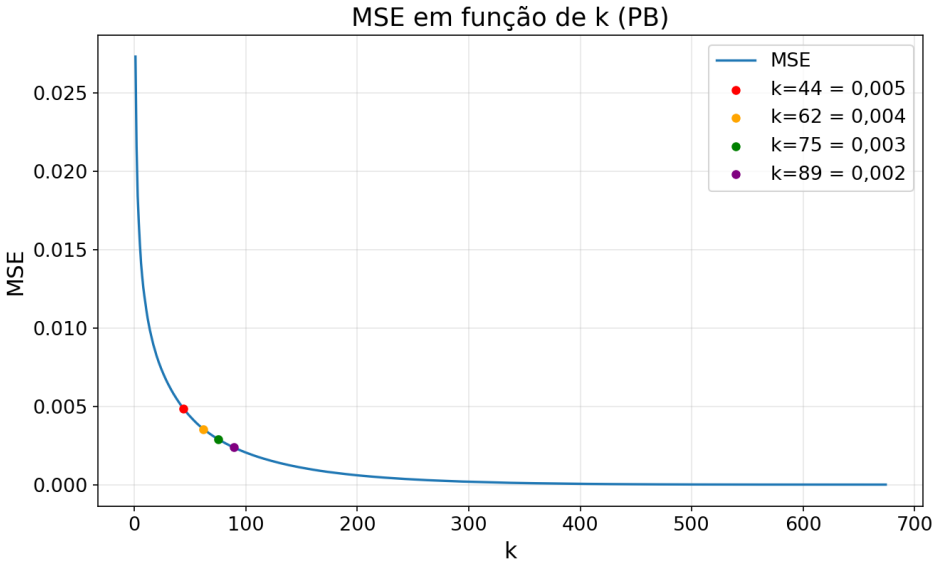
Ruído (PSNR) para avaliar a qualidade da reconstrução com base nesse erro; e a norma de Frobenius relativa para medir a diferença global entre a imagem reconstruída e a imagem original.

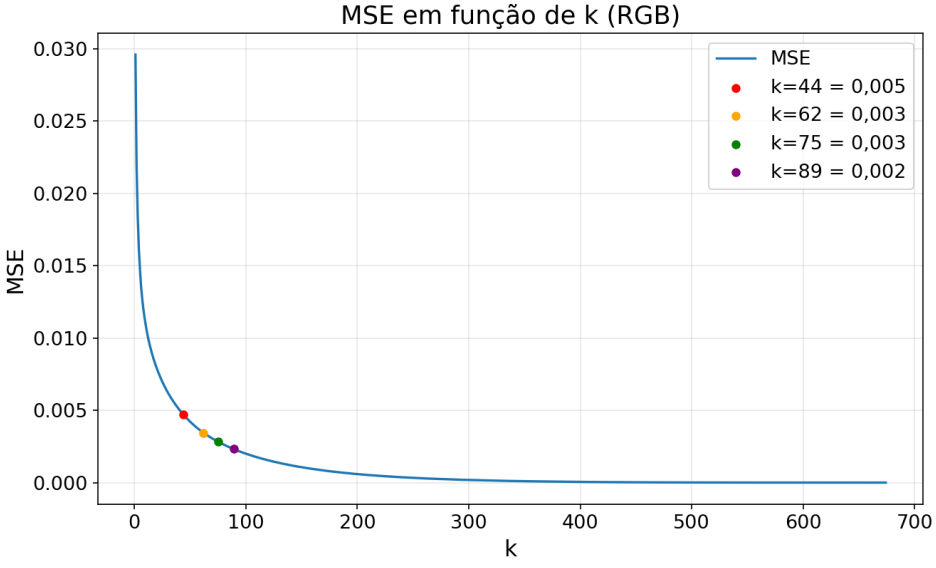
5.2.1 Mean Squared Error (MSE)

O erro quadrático médio mede a média dos quadrados das diferenças pixel a pixel entre a imagem original A e a imagem reconstruída A_k. É dada por:

$$MSE(A, A_k) = \frac{1}{nm} \sum_{i=1}^{n} \sum_{j=1}^{m} (A_{ij} - A_{k,ij})^2 \quad [3]. \tag{7}$$

Quanto menor o valor do MSE, mais próxima a imagem reconstruída estará da imagem original. Um valor igual a zero indica reconstrução idêntica.





5.2.2 Peak Signal-to-Noise Ratio (PSNR)

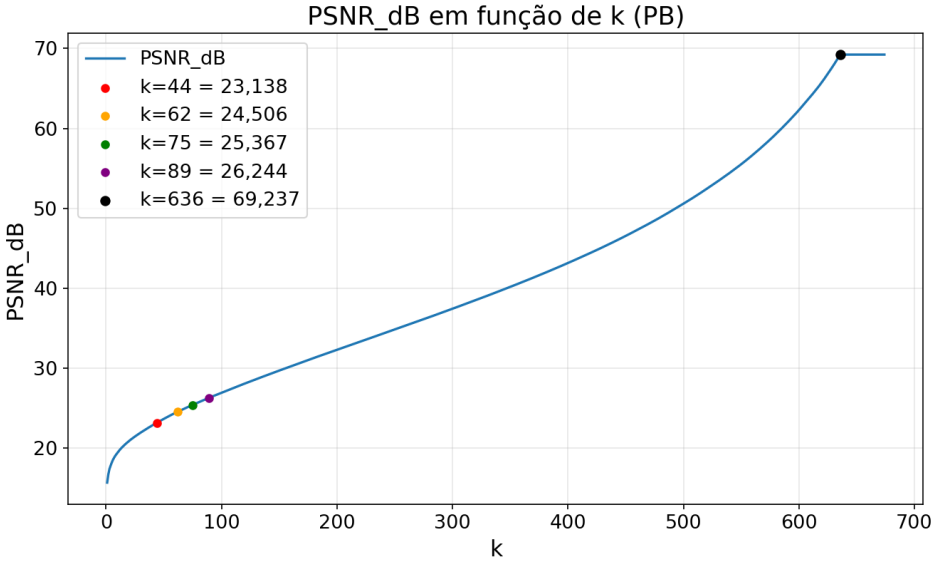
O PSNR é uma medida utilizada em processamento de imagens para medir a qualidade de reconstrução de uma imagem comprimida. Ele é definido a partir do MSE por:

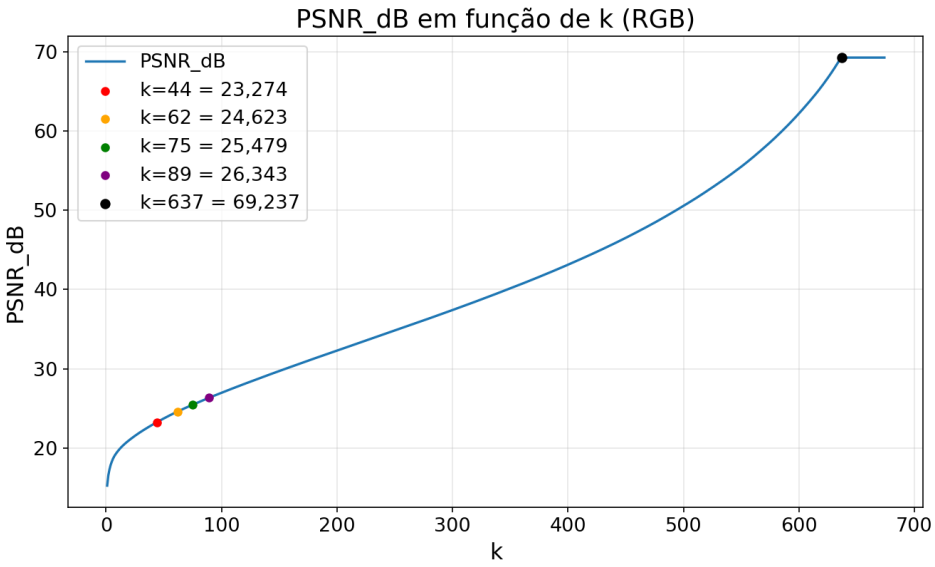
$$PSNR(A, A_k) = 10 \log_{10} \left(\frac{MAX^2}{MSE(A, A_k)} \right) \quad [3] \tag{8}$$

onde MAX representa o valor máximo possível de intensidade do pixel. Em imagens de 8 bits, utiliza $MAX = 255$ (parametrizado $MAX = 1$).

Valores maiores de PSNR indicam melhor qualidade da reconstrução. Em geral:

$$\begin{cases} PSNR > 40dB: & \text{perda quase imperceptível;} \\ 30 \leq PSNR \leq 40dB: & \text{boa qualidade visual;} \\ PSNR < 30dB: & \text{pode haver degradação perceptível.} \end{cases}$$





Veja que a partir de certo k, 636 para a imagem PB e 637 para a imagem RGB, o PSNR permanece constante, isso ocorre porque os valores singulares usados após esses k possuem uma contribuição desprezível dentro da precisão do `float32` utilizada no algoritmo que é de ordem 10^{-7}, ou seja, as diferenças entre reconstruções a partir desses k tornam-se pequenas o suficiente para não produzir alterações observáveis no MSE e, consequentemente, no PSNR, fazendo com que os valores permaneçam numericamente indistinguíveis no formato exibido.

5.2.3 Norma de Frobenius do erro

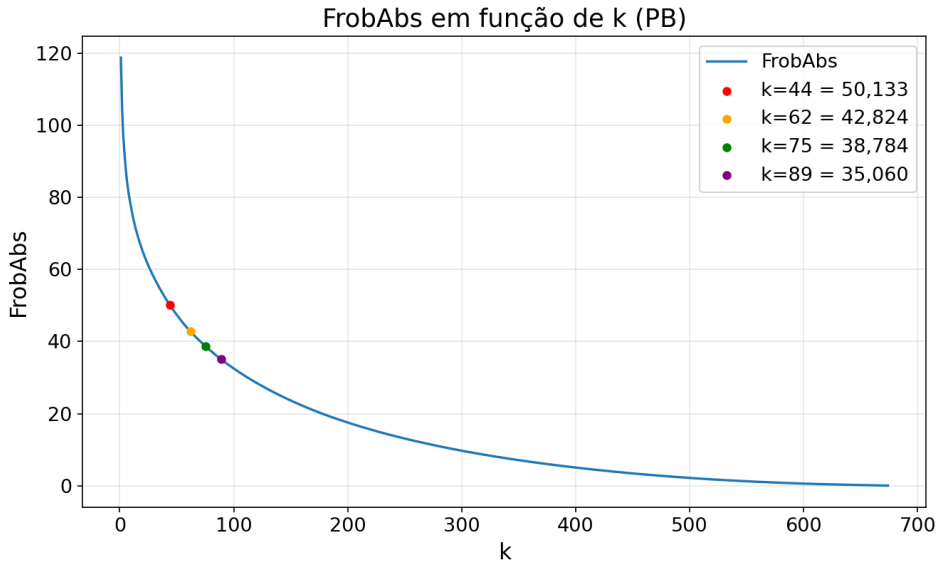
E por fim, a norma de Frobenius do erro de reconstrução:

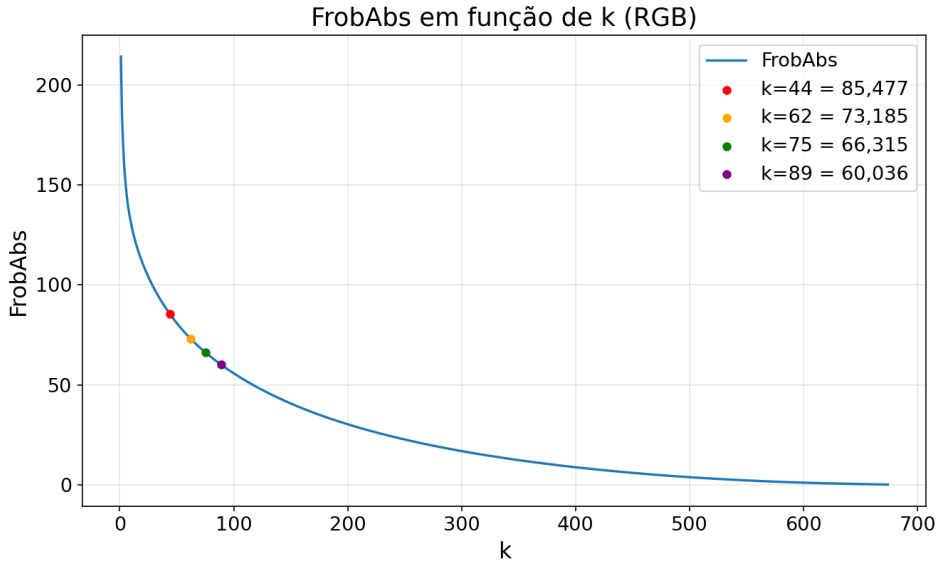
$$\|A - A_k\|_F = \sqrt{\sum_{i=1}^{n}\sum_{j=1}^{m}(A_{ij} - A_{k,ij})^2} \quad [2] \tag{9}$$

Essa métrica mede a magnitude global do erro acumulado na aproximação. Pelo Teorema de Eckart-Young, a matriz truncada A_k minimiza essa quantidade entre todas as matrizes de posto menor ou igual a k. Além disso:

$$\|A - A_k\|_F = \sqrt{\sum_{i=k+1}^{r}\sigma_i^2} \tag{10}$$

mostrando que o erro depende diretamente dos valores singulares descartados.





6 Considerações Finais

A compressão via Decomposição em Valores Singulares nos forneceu resultados agradáveis, especialmente para imagens de alta resolução que foram testadas experimentalmente. Nos experimentos foi possível obter aproximações visualmente e numericamente próximas da imagem original que possue um tamanho T de armazanamento significativamente menor de dados, principalmente para valores de k pequenos, nos quais a representação por meio da SVD ainda mantém uma taxa de compressão favorável sem comprometer a qualidade da imagem comprimida.

Referências

[1] J. Bezanson, A. Edelman, S. Karpinski, and V. B. Shah. Julia: A fresh approach to numerical computing. *SIAM Review*, 59(1):65–98, 2017. v1.12.6.

[2] G. H. Golub and C. F. Van Loan. *Matrix computations*, volume 3. JHU press, 2013.

[3] R. C. Gonzalez and R. E. Woods. *Processamento de imagens digitais*. Editora Blucher, 2000.

[4] D. S. Watkins. *Fundamentals of matrix computations*. John Wiley & Sons, 2004.